

# Documentatie

Antonie Aureliu Valentin 334CB

Am urmarit progresia din tema:

„ 1. Începeți cu Secțiunea 1 — puneți pe picioare un MLP simplu și un CNN simplu care se antrenează pe imaginile brute.

2. Adăugați Secțiunea 2 (TensorBoard) ca să puteți compara experimentele clar.

3. Adăugați Secțiunea 5 (BatchNorm) în arhitectura CNN-ului — ar trebui să observați convergență mai rapidă și posibilitatea de a folosi un learning rate mai mare.

4. Adăugați Secțiunea 3 (augmentări) și veți observa cum se reduce diferența între curbele de train și val.

5. Dacă setul vostru de date este dezechilibrat (mai ales pentru sarcina cu mole-uri), aplicați Secțiunea 4.

6. Odată ce modelul antrenat de la zero atinge un platou, treceți la Secțiunea 6 (fine-tuning pe ResNet/MobileNet) — de obicei aici apare cel mai mare salt de acuratețe pe seturile mici.

7. Încercați Secțiunea 7 (curriculum) doar peste un baseline care funcționează deja, ca rafinament suplimentar.”

1.MLP = retea neurala cu activare directa care contine unul sau mai multe straturi de noduri intre nodurile de intrare si nodurile de iesire. Aceste straturi suplimentare reprezinta nivelele ascunse ale perceptronilor multi-nivel.

**MLP simplu**


**Fara dropout**

**20 epoci**


**2 straturi liniare**

**Optimizator – Adam cu learning rate egal cu 1e-3**


**LR Scheduling nu am folosit**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.6960

F1 Micro: 0.6960

F1 Macro: 0.3244

#### Kaggle

F1 Macro: 0.38285 > **0.2**

### you-re-on-candid-camera

#### local

Accuracy: 0.6168

F1 Micro: 0.6168

F1 Macro: 0.4846

#### Kaggle

F1 Macro: 0.54609 > **0.19**

## Analiza

Se observa cresterea acuratetii pe setul de train, dar stagnarea / oscilarea pe cel de test.

Se observa scaderea drastica a loss-ului pe setul de train si cresterea dupa o anumita epoca / oscilarea pe cel de test.

Astfel, modelul face **overfitting**, nefiind capabil sa generalizeze.

Observam ca valoarea F1 Macro este mica (< F1 Micro), asta insemnand ca modelul este bun pentru clasele frecvente si slab pe cele rare, setul fiind dezechilibrat.

## MLP simplu


**Cu dropout 0.3 (30%)**

**20 epoci**


**2 straturi liniare**

**Optimizator – Adam cu learning rate egal cu 1e-3**


## LR Scheduling nu am folosit




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.6875

F1 Micro: 0.6875

F1 Macro: 0.2795

#### Kaggle

F1 Macro: 0.29900 > **0.2**

### you-re-on-candid-camera

#### local

Accuracy: 0.6053

F1 Micro: 0.6053

F1 Macro: 0.4638

#### Kaggle

F1 Macro: 0.48865 > **0.19**

### Analiza

Graficele pe train si test au aceeaasi forma, in crestere, punand in lumina faptul ca modelul nu mai face overfitting, datorita stratului de dropout.

Dropout cu probabilitate 30%, inseamna ca, la fiecare pas, 30% din neuroni sunt dezactivati. Daca alegeam o probabilitate mai mica, modelul ar fi facut tot overfitting, iar daca as fi ales un procentaj mai mare, modelul nu ar fi fost antrenat suficient, facand underfitting.

Se observa faptul ca F1 Macro este tot mic. Desi modelul nu mai face overfitting, dezechilibrul are un impact dominant. F1 Macro, mai mult, a scazut. Acest lucru este datorat faptului ca modelul MLP este slab, iar regularizarea a avut un efect negativ asupra modelului, facandu-l sa faca underfit pe clasele minoritare.

## CNN

CNN = o secventa de straturi de convolutie intercalate cu functii de activare

**Fara BatchNorm**

**Fara bias**

**Fara dropout**

**20 epoci**

**3 straturi convolutionale**


**1 strat liniar**

**Optimizator – Adam cu learning rate egal cu  $1e-3$**

**kernel\_size=3**


**stride=1**

**padding=1**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**






Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.7189

F1 Micro: 0.7189

F1 Macro: 0.3271

#### Kaggle

F1 Macro: 0.29386 < **0.4**

**you-re-on-candid-camera**

**local**

Accuracy: 0.4230

F1 Micro: 0.4230

F1 Macro: 0.1684

**Kaggle**

F1 Macro: 0.18765 < **0.35**

**Analiza**

Modelul are 3 straturi convolutionale. Fiecare bloc aplica o convolutie (fara bias, pentru a fi compatibil nativ cu BatchNorm), urmata de o functie de activare non-liniara ReLU (pentru a introduce nelinearitatea necesara modelarii tiparelor complexe).

Se observa, din cresterea similara, ca modelul **nu** face **overfitting**.

Din cauza ca acuratetea este relativ mica, inseamna ca modelul nu este antrenat suficient, deci face **underfitting**.

Se observa, la fel, ca scorul F1 Macro este mic, modelul nereusind sa fie corect pe clasele rare, acest lucru este datorat faptului ca setul este foarte dezechilibrat.

Se vede clar o diferenta majora de acuratete intre setul **vai-de-pielea-mea** si **you-re-on-candid-camera**. Acestu lucru este cauzat de diferentele majore de depistare a claselor. La setul medical, diferenta intre boli se face pe trasaturi mari, cum ar fi forma alunitei, culoarea etc. La setul de expresii, diferenta se face pe trasaturi faciale mici, modelul fiind prea slab sa le decteze. Un alt motiv poate fi faptul ca pozele medicale sunt standardizate, iar cele cu fetele oamenilor varza enorm: pot fi unghiuri diferite, cu ochelari, de la apropiere, departare etc.

2. TensorBoard

Am adaugat TensorBoard pentru a putea compara mai usor experimentele produse si pentru a nu mai face toate graficele manual.

3. **CNN**

**Cu BatchNorm**

**Fara bias**

**Fara dropout**

**20 epoci**

**3 straturi convolutionale**


**1 strat liniar**

**Optimizator – Adam cu learning rate egal cu 1e-3**


**kernel\_size=3**

**stride=1**


**padding=1**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

**vai-de-pielea-mea**

## local

Accuracy: 0.7244

F1 Micro: 0.7244

F1 Macro: 0.3437

## Kaggle

F1 Macro: 0.31906 < **0.4**

## you-re-on-candid-camera

## local

Accuracy: 0.4105

F1 Micro: 0.4105

F1 Macro: 0.1376

## Kaggle

F1 Macro: 0.17248 < **0.35**

## Analiza

BatchNorm reprezinta o tehnica la CNN prin care se standardizeaza input-uri la fiecare strat al retelei.

La setul **vai-de-pielea-mea** se observa ca acuratetea converge mai repede si este stabila. In plus, loss-ul scade mai repede si mai mult. Pe acest set de date nu se face overfitting, bazat pe grafice.

La setul **you-re-on-candid-camera**, se vede clar un dezechilibru al graficelor. Se observa clar ca modelul face **overfitting**, deoarece loss-ul pe setul de evaluare fluctueaza, iar acuratetea dupa epoca 16 incepe sa scada. Desi pare paradoxal, acest lucru este perfect normal. Inainte, modelul facea underfitting, iar dupa BatchNorm, eficienta de optimizare a crescut, ducand la o memorare agresiva, deci overfitting.

Se observa, ca in modelele anterioare, ca scorul F1 Macro este mic, modelul nereusind sa fie corect pe clasele rare. Acest lucru este datorat faptului ca setul este foarte dezechilibrat.

## 4. CNN

### Cu BatchNorm

### Fara adaptiveavgpool

### Fara bias

**Cu dropout**

**Cu augmentari geometrice**

**20 epoci**

**3 straturi convolutionale**


**1 strat liniar**

**Optimizator – Adam cu learning rate egal cu  $1e-3$**

**kernel\_size=3**

**stride=1**


**padding=1**




**Rezultatul augmentarii geometrice si standardizarii asupra setului vai-de-pielea-mea**



**Rezultatul augmentarii geometrice si standardizarii asupra setului you-re-on-candid-camera**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**




Matrice confuzie pentru setul **vai-de-pielea-mea**





Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

**Metrici (local) si rezultat Kaggle:**

**vai-de-pielea-mea**

**local**

Accuracy: 0.7594

F1 Micro: 0.7594

F1 Macro: 0.4815

### **Kaggle**

F1 Macro: 0.45026 > **0.4**

### **you-re-on-candid-camera**

#### **local**

Accuracy: 0.7523

F1 Micro: 0.7523

F1 Macro 0.6566

### **Kaggle**

F1 Macro: 0.70531 > **0.35**

### **Analiza**

Setul de train este redus. Astfel, augmentarile (de toate tipurile) sunt foarte utile, deoarece cresc artificial setul de date, aplicand diverse transformari geometrice / matematice.

Ca si augmentari geometrice, am folosit:

- La setul vai-de-pielea-mea: RandomHorizontalFlip, RandomVerticalFlip si RandomRotation(degrees=30 deoarece pozele alunitelor pot fi facute din toate unghiurile (altfel imaginile pot fi rotite si/sau oglindite)
- La setul you-re-on-candid-camera: RandomHorizontalFlip si RandomRotation(degrees=10). Aici, nu am mai folosit toate augmentarile de la celalalt set, deoarece fetele oamenilor nu pot fi rotite la unghiuri mari sau nu pot fi flipuite pe verticala, adica un om nu poate sta cu susul in jos.

Am folosit dropout cu probabilitate 30%, insemnand ca, la fiecare pas, 30% din neuroni sunt dezactivati. Am facut acest lucru pentru a elimina din overfitting-ul de pe setul de date de antrenare.

Am eliminat adaptiveavgpool, pentru a nu distruge geometria / locatia trasaturilor. In schimb, am folosit flatten care pastreaza coordonata spatiala.

Din grafice observam clar reducerea diferentelor dintre train si test. Modelul nu mai face overfit si nici underfit, fiind stabil. Se observa clar si cresterea F1 Macro, atat pe local,

cat si pe kaggle, ceea ce inseamna ca modelul invata sa prezica si clasele rare, generalizand.

## CNN

**Cu BatchNorm**

**Fara adaptiveavgpool**

**Fara bias**

**Cu dropout**

**Cu augmentari culoare**

**20 epoci**

**3 straturi convolutionale**


**1 strat liniar**

**kernel\_size=3**

**stride=1**

**padding=1**


**Optimizator – Adam cu learning rate egal cu 1e-3**




**Rezultatul augmentarii in spatiul de culoare si standardizarii asupra setului vai-de-pielea-mea**




**Rezultatul augmentarii in spatiul de culoare si standardizarii asupra you-re-on-candid-camera**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

**vai-de-pielea-mea**

**local**

Accuracy: 0.726

F1 Micro: 0.726

F1 Macro: 0.468

### **Kaggle**

F1 Macro: 0.47279 > **0.4**

### **you-re-on-candid-camera**

### **local**

Accuracy: 0.755

F1 Micro: 0.755

F1 Macro: 0.663

### **Kaggle**

F1 Macro: 0.68041 > **0.35**

### **Analiza**

Setul de train este redus, de aceea augmentarile (de toate tipurile) sunt foarte utile, deoarece cresc artificial setul de date, aplicand diverse transformari geometrice / matematice.

Ca si augmentari in spatiul de culoare, am folosit:

- La setul vai-de-pielea-mea: transforms.ColorJitter(brightness=0.2,contrast=0.2, saturation=0.1,hue=0.0) si transforms.GaussianBlur(kernel\_size=(3, 3),sigma=(0.1, 2.0))
- La setul you-re-on-candid-camera: transforms.ColorJitter(brightness=0.35, contrast=0.35, saturation=0.2, hue=0.06), transforms.GaussianBlur(kernel\_size=(3, 3), sigma=(0.1, 1.5)) si transforms.RandomGrayscale(p=0.01)

Am folosit augmentarile de mai sus deoarece pozele pot aparea luminate in diferite moduri, blurate sau cu un contrast diferit.

Am folosit dropout cu probabilitate 30%, insemnand ca, la fiecare pas, 30% din neuroni sunt dezactivati. Am facut acest lucru pentru a elimina din overfitting-ul de pe setul de date de antrenare.

Am eliminat adaptiveavgpool, pentru a nu distruge geometria / locatia trasaturilor. In schimb, am folosit flatten care pastreaza coordonata spatiala.

Din grafice observam ca modelul face **overfit**, deoarece acuratetea pe train creste constant, iar acuratetea pe val nu creste / stagneaza. Acelasi lucru, dar in alte cuvinte - loss-ul pe train scade constant, iar loss-ul pe val nu scade / stagneaza. Modelul face overfit, deoarece augmentarile in spatiul de culoare pot face ca alunita sa para a fi rezultatul unei boli diferite sau microexpresiile sa fie distruse. Solutia este de a folosi augmentari in spatiul de culoare mai putin agresive.

Se observa clar si cresterea F1 Macro, atat pe local, cat si pe Kaggle, ceea ce inseamna ca modelul invata sa prezica si clasele rare, generalizand.

## CNN

**Cu BatchNorm**

**Fara adaptiveavgpool**

**Fara bias**

**Cu dropout**

**Cu toate augmentarile**

**20 epoci**


**3 straturi convolutionale**

**Optimizator – Adam cu learning rate egal cu  $1e-3$**

**kernel\_size=3**

**stride=1**


**padding=1**



**Rezultatul augmentarilor si standardizarii asupra setului vai-de-pielea-mea**




**Rezultatul augmentarilor si standardizarii asupra setului you-re-on-candid-camera**




**Graficele de loss si accuracy pentru setul vai-de-pielea-mea**






Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.737

F1 Micro: 0.737

F1 Macro: 0.474

#### Kaggle

F1 Macro: 0.55436 > **0.4**

### you-re-on-candid-camera

## **local**

Accuracy: 0.743

F1 Micro: 0.743

F1 Macro: 0.570

## **Kaggle**

F1 Macro: 0.60406 > **0.35**

## **Analiza**

Graficele arata ca nu avem situatii de overfit, sau undefit.

Observam totusi o crestere a scorurilor la setul medical si o scadere la setul de expresii faciale. Acest lucru este datorat faptului ca am aplicat si augmentari geometrice, fata de ultima analiza, unde am aplicat doar augmenatari in spatiul de culoare. La setul medical, augmentarile geometrice au ajutat deoarece au marit setul de date, prin exemple realiste: alunitelile pot parea in tot felul de unghiuri si pozitii. La celalalt set, nu a functionat deoarece fetele oamenilor nu pot aparea rotite la anumite unghiuri (spre ex: un om nu poate sta cu susul in jos).

Am folosit dropout cu probabilitate 30%, insemnand ca, la fiecare pas, 30% din neuroni sunt dezactivati. Am facut acest lucru pentru a elimina din overfitting-ul de pe setul de date de antrenare.

Am eliminat adaptiveavgpool, pentru a nu distruge geometria / locatia trasaturilor. In schimb, am folosit flatten care pastreaza coordonata spatiala.

## **5. CNN**

**Cu BatchNorm**

**Fara adaptiveavgpool**

**Fara bias**

**Cu dropout**

**Cu toate augmentarile**

**20 epoci**

**3 straturi convolutionale**


**Cross Entropy ponderat**

**Optimizator – Adam cu learning rate egal cu 1e-3**


**kernel\_size=3**

**stride=1**


**padding=1**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

**Metrici (local) si rezultat Kaggle:**

## **vai-de-pielea-mea**

### **local**

Accuracy: 0.567

F1 Micro: 0.567

F1 Macro: 0.364

### **Kaggle**

F1 Macro: 0.41776 > **0.4**

## **you-re-on-candid-camera**

### **local**

Accuracy: 0.604

F1 Micro: 0.604

F1 Macro: 0.469

### **Kaggle**

F1 Macro: 0.44297 > **0.35**

## **Analiza**

Cross entropy ponderat functioneaza prin a asigna weights mai mari claselor mai rare, pentru ca modelul sa nu fie afectat de dezechilibrul masiv al claselor.

Observam ca modelul face **underfit** si nu e stabil, avand rezultate clar mai mici fata de modulul trecut. Face underfit, deoarece clasele fiind balansate, prin cross entropy ponderat, problema a devenit mai grea, deci modelul converge mai lent. Nu e stabil, deoarece learning rate-ul este prea mare, iar cand modelul greseste pe o clasa rara, acuratetea scade brusc (ponderile sunt mari pe clasele rare).

Am folosit dropout cu probabilitate 30%, insemnand ca, la fiecare pas, 30% din neuroni sunt dezactivati. Am facut acest lucru pentru a elimina din overfitting-ul de pe setul de date de antrenare.

Am eliminat adaptiveavgpool, pentru a nu distruge geometria / locatia trasaturilor. In schimb, am folosit flatten care pastreaza coordonata spatiala.

## **CNN**

### **Cu BatchNorm**

**Fara adaptiveavgpool**

**Fara bias**

**Cu dropout**

**Cu toate augmentarile**

**40 epoci**

**3 straturi convolutionale**

**Cross Entropy ponderat**


**Optimizator – Adam cu learning rate egal cu  $1e-4$**

**LR scheduling**


**kernel\_size=3**

**stride=1**


**padding=1**



Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**




Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**





Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.609

F1 Micro: 0.609

F1 Macro: 0.447

#### Kaggle

F1 Macro: 0.49573 > **0.4**

**you-re-on-candid-camera**

**local**

Accuracy: 0.728

F1 Micro: 0.728

F1 Macro: 0.646

**Kaggle**

F1 Macro: 0.68074 > **0.35**

### **Analiza**

Cross entropy ponderat functioneaza prin a asigna weights mai mari claselor mai rare, pentru ca modelul sa nu fie afectat de dezechilibrul masiv al claselor.

Pe baza graficelor, vedem ca modelul nu mai face underfit. Modificarea numarului de epoci (de la 20 la 40) a ajutat masiv la obtinerea unui scor net superior. In schimb, scaderea learning rate-ului si utilizarea LR scheduling a facut ca modelul sa fie mult mai stabil. Astfel, nu mai exista scaderi masive pe graficul de acuratetea, datorate de gresirea unei clase rare. LR scheduling functioneaza prin scaderea learning rate-ului, treptat. In codul meu, am folosit o scadere bazata pe cosinus.

BatchNorm a ajutat pentru o convergenta mai rapida si a facilitat posibilitatea de a folosi un learning rate mai mare.

Am folosit dropout cu probabilitate 30%, insemnand ca, la fiecare pas, 30% din neuroni sunt dezactivati. Am facut acest lucru pentru a elimina din overfitting-ul de pe setul de date de antrenare.

Am eliminat adaptiveavgpool, pentru a nu distruge geometria / locatia trasaturilor. In schimb, am folosit flatten care pastreaza coordonata spatiala.

### **6. ResNet-18**

**2 layere dezghetate**

**resize 224x224**


**fara learning rate warmup**

**Cu dropout**


**Cu toate augmentarile**

**40 epoci**


**Cross Entropy ponderat**




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.775

F1 Micro: 0.775

F1 Macro: 0.718

#### Kaggle

F1 Macro: 0.69652 > **0.67**

### you-re-on-candid-camera

#### local

Accuracy: 0.783

F1 Micro: 0.783

F1 Macro: 0.681

#### Kaggle

F1 Macro: 0.71113 < **0.77**

### Analiza

Am facut resize-ul la 224x224, deoarece modelul a fost preantrenat pe imagine de aceasta dimensiune.

Din grafice ne dam seama clar ca modelul face **overfit**, deoarece loss-ul scade constant la train, iar loss-ul la evaluare stagneaza / acuratetea creste mereu la train, iar la val stagneaza. Modelul face overfitting, deoarece nu avem warmup si avem 2 straturi dezghetate. Am folosit 2 straturi dezghetate si nu unul singur, pentru a avea o acuratete mai mare, chiar cu riscul overfitting-ului.

Un aspect foarte pozitiv la modelul acesta este faptul ca F1 Macro este apropiat de F1 Micro, ceea ce inseamna ca modelul „trateaza” la fel toate clasele (rare sau dese).

## ResNet-18

2 layere dezghetate

resize 224x224


cu learning rate warmup

Cu dropout


Cu toate augmentarile

40 epoci


Cross Entropy ponderat




Graficele de loss si accuracy pentru setul **vai-de-pielea-mea**



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.788

F1 Micro: 0.788

F1 Macro: 0.709

#### Kaggle

F1 Macro: 0.71875 > **0.67**

### you-re-on-candid-camera

#### local

Accuracy: 0.783

F1 Micro 0.783

F1 Macro: 0.681

#### Kaggle

F1 Macro: 0.69304 < **0.77**

### Analiza

Putem observa 2 lucruri majore realizate de warmup, cresterea acuratetii / F1 Macro si scaderea overfitting-ului. Learning rate warmup incepe cu un lr mic, iar apoi il creste treptat, pentru a stabili modelul. Acest lucru este indeosebi folosit pentru a evita blocarea in minime locale. Prin cresterea graduala a learning rate-ului, se evita modificarea drastica de la inceputul modelului, inceput in care poate memora zgomotul setului de date.

### ResNet-18

#### 3 layere dezghetate

resize 224x224 (cu random crop)

cu learning rate warmup

Cu dropout

Cu toate augmentarile



40 epoci


Cross Entropy ponderat




Rezultatul augmentarilor si standardizarii asupra setului vai-de-pielea-mea




Rezultatul augmentarilor si standardizarii asupra setului you-re-on-candid-camera




Graficele de loss si accuracy pentru setul vai-de-pielea-mea



Matrice confuzie pentru setul **vai-de-pielea-mea**



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

## Metrici (local) si rezultat Kaggle:

### vai-de-pielea-mea

#### local

Accuracy: 0.761

F1 Micro: 0.761

F1 Macro: 0.701

#### Kaggle

F1 Macro: 0.72719 > **0.67**

### you-re-on-candid-camera

#### local

Accuracy: 0.812

F1 Micro: 0.812

F1 Macro: 0.722

### Kaggle

F1 Macro: 0.70813 < **0.77**

### Analiza

Fata de modelul anterior, am schimbat doua lucruri:

- Am modificat modul in care dau crop la o imagine de 224x224. In modelul trecut, luam imaginea centrata in centrul imaginii originale, acum o iau random. Fac acest lucru pentru a replica mai bine pozele din realitate. Fetele in poze nu sunt mereu centrate in mijloc.
- Am mai adaugat un strat dezghetat. In varianta cu 2 straturi, am dezghetat straturile care se ocupa de conceptele ultra-abstracte. In varianta curenta, am dezghetat si layer2. Acest lucru a facut ca acuratetea sa creasca putin mai repede, dar este o diferenta minora.

Pentru a depasi pragul pe Kaggle, am facut urmatoarea observatie: setul de date este redus - o metoda este sa folosim augmentari pentru a creste artificial setul de train. Pe langa acest aspect, un lucru si mai bun de facut este sa antrenam si pe setul de evaluare local, pentru ca si acesta contine poze (diferite), reale, nu generate artificial.

### Kaggle

F1 Macro: 0.78366 > **0.77**

## Noile metrice Kaggle

**F1 Macro vai-de-pielea-mea 0.74527 > 0.67**

**F1 Macro you-re-on-candid-camera 0.78366 > 0.77**

### 7. ResNet-18

**3 layere dezghetate**

**resize 224x224 (cu random crop)**

**cu learning rate warmup**


**Cu dropout**

**Cu toate augmentarile**


**40 epoci**

## Cross Entropy ponderat

### Self-paced learning



Graficele de loss si accuracy pentru setul **you-re-on-candid-camera**



Matrice confuzie pentru setul **you-re-on-candid-camera**

Accuracy: 0.799

F1 Micro: 0.799

F1 Macro: 0.715

Kaggle score **0.72108** (vs 0.70813)

În primul rând, vreau să specific că nu am antrenat pe train + test, ci doar pe train. Dacă comparăm cu rezultatele modelului anterior, antrenat doar pe train, observăm o creștere a scorului considerabilă.

Curriculum learning este inspirat de modul în care învață oamenii: începem cu exemple ușoare și introducem treptat exemple mai grele. Empiric, această abordare conduce adesea la convergență mai rapidă și la o generalizare mai bună, mai ales pe seturi de date zgomotoase sau dezechilibrate. Acest lucru se poate vedea pe grafice și în matricea de confuzie.

Implicit, algoritmul Self-paced learning calculează la fiecare pas „dificultatea”, pe baza loss-ului, iar în funcție de epocă curentă alege un procent mai mare sau mai mic din setul de date. Spre exemplu, în epoca 1 pragul este de 0.30, adică modelul selectează cele mai ușoare 30% din imagini. La epoca 5, pragul devine 0.50, adică modelul învață acum cele mai ușoare 50% din imagini și tot așa.